THUD: opis slike in stabilnost objektov

Vmesno poročilo za predstavitev 21. 10. 2026

Osnutek za poznejši ročni pregled in dopolnitev

Cilj in postopek

Robot za dolgoročno karto potrebuje opis vidnih objektov in njihovih odnosov ter ločeno presojo, ali se lahko položaj spremeni med obiski. Trenutna negibnost na fotografiji ni dokaz trajnosti.

izbor slik → opis/detekcija → besedilna presoja → vrednotenje → poročilo

Prvi korak uporablja sliko, drugi samo zamrznjeni JSON opis. Razredi so `fixed`, `movable`, `uncertain`; izhod vsebuje kratko besedno utemeljitev, ne skritega notranjega razmišljanja.

Podatki in dve ločeni nalogi

Nabor	Slike	Regije
Trgovina (dense)	50	678
agtea	50	1021

Poti, mere in SHA256 vseh slik so preverjeni. To so povezani pogledi istih prostorov, ne 100 neodvisnih prizorov. Oznake vsebujejo vrste in okvirje, ne razredov stabilnosti. `Products` je lahko skupina; ID velja samo znotraj slike.

- **Samostojno zaznavanje (discovery):** ločen manifest vsebuje le nevtralni ID slike, slikovno pot, mere in SHA256. Model ne prejme referenčnih imen, regijskih ID, okvirjev ali anotacijskih poti.
- **Opisovanje danih regij (supplied):** model prejme anotirane regije, vrne njihove iste ID in imena. Kopirano ime ni detekcijski zadetek.

Modeli in nastavitve

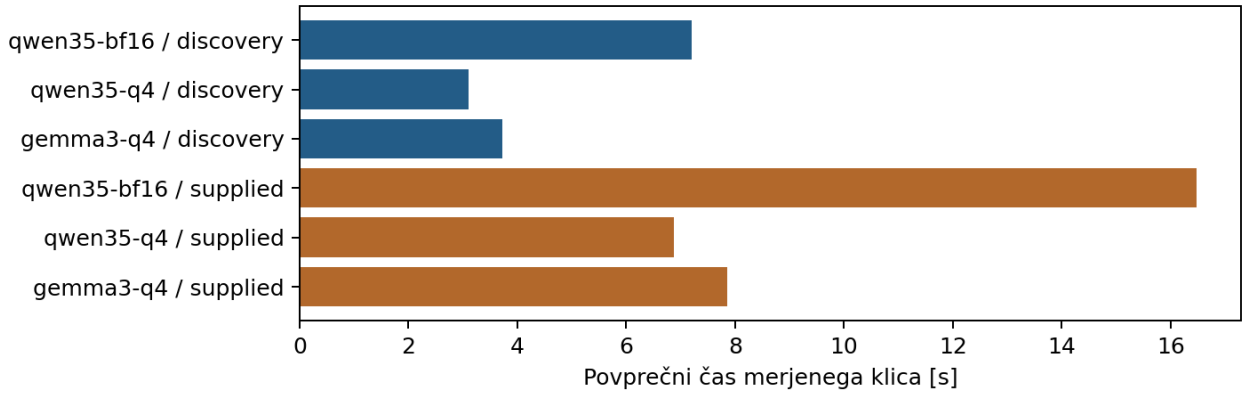
Točen model	Uteži	Projektor	VRAM [GiB]
qwen3.5:4b-bf16	BF16	F16	8.8
qwen3.5:4b-q4_K_M	Q4_K_M	BF16	3.4
gemma3:4b-it-q4_K_M	Q4_K_M	ni poročano	2.8

Točni tagi: `qwen3.5:4b-bf16`, `qwen3.5:4b-q4_K_M`, `gemma3:4b-it-q4_K_M`. Tagi in slikovna podpora so preverjeni v uradnem katalogu ter z `/api/show`. Tudi Qwen slikovna projektorja imata različni natančnosti (F16/BF16). BF16 metapodatki navajajo 33 blokov in nextn_predict_layers=1, Q4 pa 32 blokov. Zato to ni strogo izoliran poseg samo v natančnost istih pretvorjenih uteži; vpliv dodatne napovedne plasti ni posebej preverjen. Družin pri različnih natančnostih ne primerjamo kot čiste arhitekturne razlike. VRAM je največja dodelitev modelu v shranjenih merjenih odgovorih API, ne celotna zasedenost kartice. Projektor: GGUF file type iz metapodatkov, F16=1 in BF16=32. Osnova: podroben prompt brez vsebinskih primerov, $T = 0$, seed 42, kontekst 16384, izhod do 8192 tokenov, top-p 0.8, top-k 20, presence penalty 1.5. Enaki izvorni bajti slike; notranje predprocesiranje modelov se lahko razlikuje.

Dejanski obseg in hitrost

Osnovna primerjava: 600/600 merjenih odgovorov, 576 odgovorov ustreza shemi, 24 napak; skladen zapis JSON ima 600 odgovorov. Dodatni prvi korak: 80/80; drugi korak: 120/120. Dodatna Q4 ponovitev: 20/20. Ogrevalni klici so shranjeni ločeno in izključeni iz teh imenovalcev.

Nabor	Način	Model	OK/vsi	Med.	p90	Povp.	Izh. tok.	tok/s
trgovina	samost.	qwen35-bf16	50/50	8.4	17.3	10.0	486	49.9
trgovina	samost.	qwen35-q4	50/50	2.5	5.1	3.2	477	163.1
trgovina	samost.	gemma3-q4	50/50	3.0	5.6	3.6	545	170.0
trgovina	regije	qwen35-bf16	49/50	9.1	13.1	9.5	1057	115.8
trgovina	regije	qwen35-q4	50/50	5.3	8.4	5.9	1044	186.9
trgovina	regije	gemma3-q4	46/50	6.6	9.5	6.9	1137	180.5
agtea	samost.	qwen35-bf16	50/50	4.2	5.7	4.4	534	127.8
agtea	samost.	qwen35-q4	50/50	2.8	4.4	3.1	564	198.9
agtea	samost.	gemma3-q4	50/50	3.3	6.4	3.9	642	182.7
agtea	regije	qwen35-bf16	45/50	19.1	47.5	23.5	1479	64.3
agtea	regije	qwen35-q4	47/50	7.2	10.8	7.8	1464	197.7
agtea	regije	gemma3-q4	39/50	8.8	11.7	8.8	1487	180.5



Izh. tok. je povprečno število izhodnih tokenov. Časi so sekunde na sliko/klic; p90 uporablja linearno interpolacijo. Čas vključuje vse odgovore z izmerjenim časom, tudi zavrnjeni JSON. Napake prenosa lahko nimajo časa; število takih klicev je v agregatih. Tok/s je vsota izhodnih tokenov deljena z vsoto API časa generiranja. Nalaganje in tokeni so ločeno ohranjeni; end-to-end čas je čas celotne skupine, vključno z ogrevanjem, preverjanjem in zapisovanjem. Osnovni del: skupni end-to-end čas 77.4 min; ogrevalni klici 114.5 s, od tega API nalaganje 33.3 s; API nalaganje v merjenih klicih 5.7 s. Nalaganje je podmnožica časa zahteve, zato teh časov ne seštevamo. Pilot: 24 merjenih klicev; linearna ocena osnovnega dela pred polnim zagonom je bila 2.5 h. Ocena ni meritev celotnega izvajanja.

RTX 5090 (32607 MiB), Docker Compose in projektna Ollama. Začetni stari kontejner je izgubil GPU: CPU diagnostika je ohranjena ločeno, kontejner je bil ponovno ustvarjen z GPU override. Veljavni klici preverijo VRAM; delni CPU offload se zavrne. Drug uporabnikov proces je hkrati obremenjeval GPU; ni bil ustavljen. To omejuje primerjavo hitrosti. Različno dolgi odgovori in API predpomnilnik predpon/slikovnega kodiranja dodatno vplivajo na čase; svež HTTP klic ne zagotavlja hladnega predpomnilnika.

Vpliv prompta, temperature in semena

Vnaprej je izbranih 10 enakomerno razpršenih slik iz vsakega nabora (indeksi v `data-audit.json`). Vsi dodatni testi uporabijo isti izbor; dodatni opisovalni testi merijo samostojno zaznavanje. Kratek in podroben opisovalni prompt imata isto izhodno shemo in obvezne podatke, brez vsebinskih primerov. Osnovni podrobni T=0 se ponovno uporabi na izbranih slikah.

Opisovalnik BF16	OK/vsi	Med. [s]	Objekti
podroben, T=0, s42	20/20	4.2	115
kratek, T=0, s42	20/20	3.4	81
podroben, T=.3, s42	20/20	4.6	102
podroben, T=.7, s42	20/20	5.2	108
podroben, T=.3, s43	20/20	6.0	111

Število objektov je opis izhoda, ne merilo pravilnosti. Temperatura in seme se spreminjata ločeno; ni polnega kartezičnega produkta. Pri T=0 seme nima zagotovljenega vpliva.

Besedilna presoja istih zamrznjenih opisov

Vhodi so iz osnovnega samostojnega Qwen BF16. SHA256 datotek se zapiše za vsak klic; drugi korak ne odpre slike. Dolga prompta se razlikujeta samo po odstranitvi dveh blokov vsebinskih primerov. Definicije in shema ostanejo iste. Kratka različica ohrani isti pomen. Datoteke in razlike so shranjene v Git.

Prompt / T / seed	OK/vsi	F	M	U	Spremembe
long-examples / 0.3 / 42	20/20	25	66	24	26/95
long-no-examples / 0.3 / 42	16/20	25	63	7	0/95
short-no-examples / 0.3 / 42	20/20	37	63	15	14/95
long-no-examples / 0 / 42	20/20	36	71	8	6/95
long-no-examples / 0.7 / 42	19/20	33	63	14	10/90
long-no-examples / 0.3 / 43	20/20	35	73	7	12/95
Q4 / long-no-examples / .3 / 42	17/20	33	59	10	11/91

Pri T=.3, seed 42: long-examples 20/20, long-no-examples 16/20, short-no-examples 20/20. To meri izpolnitev sheme, ne pravilnosti odločitev. Vrstice so BF16, dodatna vrstica Q4 je ponovitev istega prompta in opisov. F/M/U so števila odločitev fixed/movable/uncertain v veljavnih odgovorih. Spremembe so primerjave istega tipiziranega ID na istem SHA256 opisa proti dolgemu promptu brez primerov pri T=.3, seed 42. Imenovalec vsebuje samo pare veljavnih odgovorov; neuspešni klici so posebej v OK/vsi. Strinjanje ni pravilnost. Izbira dolgega prompta brez primerov za temperaturne teste je vnaprejšnja metodološka izbira zaradi ohranjenih definicij, ne dokaz boljše kakovosti.

Kakovost: meje samodejnih meritev

`name-overlap.csv` poroča le presek unikatnih imen po pretvorbi v male črke in normalizaciji presledkov, brez sinonimov ali ujemanja instanc. Izpuščena drugačna imena niso avtomatično zgrešeni objekti, neoznačeni vidni objekti pa niso avtomatično halucinacije. Brez napovedanih okvirjev ni detekcijskega mAP; brez referenc stabilnosti ni accuracy. `manual-review.html` prikazuje iste slike, referenčne okvirje in vse izhode. Ročno nepreverjena polja v CSV ostanejo označena `pending`.

Dejanske slike in primerjava modelov

Trgovina / frame-000007



Model	Detekcija	Regije	Dejanski izsek opisa (model)
qwen35-bf16	ok: 5	ok	A retail aisle view featuring a large refrigerated display unit on the left and multiple shelving units on the right. The ceiling is dark with fluorescent lighting and hanging hot air balloon ...
qwen35-q4	ok: 4	ok	A retail aisle with refrigerated units on the left and open shelving on the right. Decorative hot air balloon lights hang from the ceiling. The floor is reflective tile. Aisles extend into the...
gemma3-q4	ok: 5	ok	The photograph depicts a retail environment, likely a supermarket or convenience store. Shelves filled with various products line the walls, extending into the depth of the image. Several refr...

Referenčna imena: Board, Fridge, Lamp, Shelf, Bottle. **Lastna presoja:** BF16 in Q4 ujameta osnovno razporeditev hladilnega dela levo in polic desno, a združujeta številne instance. Trditev o steklenih vratih levega odprtega hladilnega dela je vprašljiva. Gemma hladilnike postavi na desno ("right side"), kar se ne ujema z glavnim vidnim hladilnim delom levo. To je delni vizualni pregled.

Trgovina / frame-000030



Model	Detekcija	Regije	Dejanski izsek opisa (model)
qwen35-bf16	ok: 8	ok	An indoor retail environment with stacked product boxes in the foreground and shelving units along walls. Decorative hot air balloon ornaments hang from a black ceiling with fluorescent lighti...
qwen35-q4	ok: 7	ok	A retail store interior with stacked product boxes in the foreground and shelves along the walls. Decorative hot air balloon ornaments hang from the ceiling alongside rectangular fluorescent l...
gemma3-q4	ok: 6	ok	The photograph depicts a retail store interior with a focus on a brightly lit section filled with various products. Overhead, several hot air balloon decorations are suspended from the ceiling...

Referenčna imena: Lamp, Shelf, Board, People, Fridge, Freezer, Products, Checkout, Fruits. **Lastna presoja:** Gost prizor vsebuje zakritost in skupinsko označene izdelke. BF16 izloči moškega v belem ter osebo ob hladilniku; delno zakrite osebe za moškim ne izpostavi. Referenca People ima le dve regiji, zato iz števila okvirjev ne sklepamo o vseh vidnih osebah.

Dejanske slike in primerjava modelov

agtea / frame-000002



Model	Detekcija	Regije	Dejanski izsek opisa (model)
qwen35-bf16	ok: 8	ok	Interior of a modern atrium with large floor-to-ceiling windows on the left allowing bright daylight. A tall, curved red structure dominates the right foreground. In the background, people sit...
qwen35-q4	ok: 4	ok	An indoor space with large windows on the left allowing bright light. A tall red curved structure dominates the right foreground. In the background, there are tables and chairs, some people se...
gemma3-q4	ok: 5	error	The photograph depicts a brightly lit interior space, likely a waiting area or lobby. A large window dominates the background, flooding the scene with natural light and revealing a view of tre...

Dejanska zavrnitev: gemma3-q4 / regije: Missing IDs: {('int', 2)} **Referenčna imena:** People, Chair, Window, Table, Shelf, Bag, Laptop, Plants, Spotlight, Glass, Stairs. **Lastna presoja:** BF16 stole opiše kot clear acrylic or plastic"; vidim kovinske cevaste okvirje in modra sedišča, prosojnega materiala ne potrdim. Q4 združi mize in stole v "tables and chairs". Gemma trdi, da je stol na mizi; vidni stoli stojijo na tleh. Njen opis regij izpusti ID 2 in je zavrnjen.

agtea / frame-000026



Model	Detekcija	Regije	Dejanski izsek opisa (model)
qwen35-bf16	ok: 5	ok	An indoor public space with large windows on the left and a spiral bookshelf structure in the center. People are seated at tables near the window. The floor is reflective. A red curved object ...
qwen35-q4	ok: 6	error	An indoor public space with large windows on the left and a spiral bookshelf structure in the center. Several people are seated at tables near the window, working or reading. The room has mode...
gemma3-q4	ok: 5	ok	The photograph depicts a brightly lit interior space, likely a library or bookstore, with a large, circular bookshelf dominating the central view. The bookshelf is illuminated from within and ...

Dejanska zavrnitev: qwen35-q4 / regije: A supplied label was changed. **Referenčna imena:** People, Chair, Window, Table, Shelf, Stairs, Bag, Laptop, Glass, Plants, Book. **Lastna presoja:** Vidna sta osvetljena krožna knjižna polica in več stolov; osebe, knjige in torbe so delno zakrite. Lokacija ob steni ali veliki konstrukciji sama po sebi ne dokazuje trajne stabilnosti. Celoten ročni pregled vseh instanc še ni opravljen.

Utemeljitve, napake in omejitve

Naslednji izseki so besedni razlogi modela; niso lastna potrditev vidnih dokazov. Primeri so izbrani iz vrat, slik, polic in pohištva, kjer so te vrste dejansko vrnjene. Hladilnih vrat ne enačimo z vrati prostora. Če slik/umetniških del opisovalnik ne izloči, njihovega razvrščanja ne prikazujemo kot izmerjenega. Celotni pari z imenom poskusa in SHA256 so v `reasoning-comparisons.csv`.

Objekt	Osnova → različica	Dejanski modelov razlog
Vrata: Glass door	fixed → fixed	Structural building element; opening is not relocation. trgovina / image-000050 / ID 2 / long-examples-t0.3-s42
Slike	–	Ni samostojnega predmeta te vrste v primerjanih veljavnih opisih.
Police: shelving unit	fixed → uncertain	Shelving could be bolted or on wheels; evidence missing. trgovina / image-000006 / ID 5 / long-examples-t0.3-s42
Pohištvo: desk	movable → fixed	Desk is a structural element integrated into the room layout. agtea / image-000012 / ID 2 / long-no-examples-t0-s42

V besedilnem delu je 5 odgovorov brez obvezne utemeljitve in 2 s podvojenim ključem ter 1 z drugimi kršitvami sheme. Vsi ostanejo zavrnjeni s shranjenim surovim odgovorom; podvojenega ključa ne razrešimo z izbiro zadnje vrednosti.

NVILA 8B: zgodovinsko stanje ob koncu 1. dela

Ob koncu 1. dela dodatni model še ni bil izveden. Omejena začetna diagnostika: uradna validacijska shema ne vključuje `NVILA-8B`, izolirani venv pa je odpovedal zaradi manjkajočega ensurepip. Takrat uteži še niso bile prenesene in slikovni API ni bil preverjen; 8B ni preimenovan v 15B. Celotne začetne ovire so v `nvila-diagnostic.json`; dejanski kasnejši GPU zagon je opisan v dodatku NVILA/Florence, kadar je prisoten.

Ponovljivost in izvor

Preverjanje kode: 54 testov (OK); revizija 34/34 skupin, 0 kršitev nespremenljivih vhodov/GPU. Podrobnosti: tests.json in verification.json. Izhodiščni Git commit: `399d6ea6c53f`. Različice, gonilnik in slika Docker so v `environment.json`; točna natančnost, slikovni projektor in zmožnosti v manifestih posameznih poskusov. Konfiguracije vsebujejo vse nastavitve, shranjeni odgovori pa prompte, SHA256 slike/opisa, čas, možnosti, GPU stanje in surovi API odgovor.

```
bash scripts/thud_experiment.sh --phase all
python3 -m llm_object_classifier.thud_q4_repeat
python3 -m llm_object_classifier.thud_verify --require-complete
python3 -m llm_object_classifier.thud_report
bash scripts/compile_thud_report.sh
python3 -m unittest discover -s tests -v
```

Zaganjalnik uporablja projektno Ollamo (privzeti omrežni naslov lahko nastavimo z `-base-url`). Predpogoji: zdrava GPU Ollama, preneseni trije tagi, Python s Pillow. Vsaka dokončana skupina dobi oznako; nadaljevanje preverja nespremenljivost vhodov in ne prepisuje odgovorov. Prekinjeni poskusi drugega koraka ostanejo kot ločeni poskusi. Veliki surovi izhodi: `results/thud-vmesno/`. Majhen paket PDF/LaTeX, slike, agregati, izbor, preglednica in metodologija: `reports/THUD_VMESNO/`. Stari NYU poskusi ostanejo ločeni.

Naslednji utemeljeni poskus

Za naslednji ročni pregled izberemo kratki prompt brez primerov kot kandidata: primerjava sheme zgoraj podpira njegov operativni preizkus, ne dokazuje pravilnosti. Preveriti je treba iste objekte in razhajanja proti dolgemu promptu s primeri, predvsem pri policah in pohištvu. Hitrost ponoviti ob izključni uporabi GPU. Šele po primerljivi ročno potrjeni kakovosti izbrati končni prompt. To je sklep 1. dela: predlog nadaljevanja so bogatejši odnosi in vidni dokazi; dejanski 2. del je po izrecnem naročilu dokumentiran v nadaljevanju tega poročila, kadar je dodatek prisoten. NVILA ostaja ločena priprava.

Uradni viri: Qwen BF16, Qwen Q4, Gemma Q4, NVILA uteži, NVILA strežnik. Preverjeno 20. 10. 2026.

2. del: bogatejši samostojni opis (21. 10. 2026)

Nadaljevanje uporablja obstoječe izhode 1. dela (objavljen commit `7509607`); uspešni stari klici se ne ponovijo. Vsi trije delujoči modeli prejmejo iste slikovne bajte vseh 100 slik, brez referenčnih imen, ID, okvirjev ali poti anotacij. Ob izvedbi 2. dela NVILA še ni imel preverjenega slikovnega API; takrat se uporabi shranjena diagnostika brez novega prenosa ali trditve o inferenci. Kasnejši ločeni GPU zagon NVILA/Florence je dokumentiran v dodatnem nadaljevanju, kadar je prisotno.

Izhodna shema in dokazi

`rich-description-v2` ohrani `scene_description` in stare združljive podatke objektov, doda `appearance`, `image_location`, `occlusion`, `support_contacts`, `installation_evidence` ter seznam `relations`. Odnos navaja začetni/ciljni lokalni ID, predikat in vidni dokaz. Validator zavrne manjkajoče podatke, podvojene ID/odnose, sklice na neobstoječe ID, samopovezave in razrede stabilnosti v prvem koraku. Neznano je izrecno `unknown`. Nobeno besedilno polje samo ne dokazuje pravilnosti trditve. Položaji opisujejo levo/desno v sliki, ne svetovnih koordinat. Skritih vijakov, teže ali trajnosti ne zahtevamo; bližina ali negibnost ni namestitev. ID so lokalni, brez sledenja skozi čas. Napovedanih okvirjev ni; besedni položaj ni meritev natančne lokalizacije. Zato ni IoU ali mAP in na teh rezultatih še ni podlage za uvedbo posebnega detektorja.

Primerjava časa in oblike izhoda

Opisovalnik	Različica	OK/vsi	Med.	p90	Povp.	Tok.	tok/s	GiB
qwen35-bf16	1. del, podrobni	100/100	4.5	15.4	7.2	510	73.3	8.78
qwen35-bf16	2. del, bogati	69/100	11.5	19.0	13.3	1130	87.7	8.78
qwen35-q4	1. del, podrobni	100/100	2.7	4.8	3.1	521	180.7	3.40
qwen35-q4	2. del, bogati	82/100	4.1	6.1	5.1	1116	232.7	3.40
gemma3-q4	1. del, podrobni	100/100	3.1	6.2	3.7	593	176.7	2.85
gemma3-q4	2. del, bogati	89/100	4.2	5.3	4.2	857	225.6	2.85

Časi so sekunde na sliko, tudi za zavrnjene odgovore z izmerjenim časom. Tok. je povprečje izhodnih tokenov, tok/s pa hitrost API generiranja. GiB je največja API dodelitev VRAM. Ogrevanje in nalaganje sta ločena v `part2-aggregates.json`. GPU je deljen; obremenitev in dolžina odgovora omejujeta vzročno primerjavo hitrosti. Stari prompt je podroben, novi je drugačen prompt s strožjo shemo; razlike ne pripisujemo samo strukturiranju. Prekopirano pilotno ogrevanje ne pomeni ogretega modela po novem nalaganju. Prvi novi klic (indeks 3) posamezne skupine lahko vključuje nalaganje; celotni čas ostane v tabeli, API `load_duration` je ohranjen ločeno. To je dodatna omejitev neposredne primerjave hitrosti, ne prikrita izločitev počasnih klicev.

Model	Objekti	Odnosi	Opisi z odnosi	Namest. unknown	Podpora unknown
qwen35-bf16	473	182	61/69	437	468
qwen35-q4	539	218	82/82	513	539
gemma3-q4	525	151	74/89	330	523

Objekti in odnosi so šteti le v sprejetih opisih; zavrnitve ostanejo v imenovalcih zgornje tabele. Število odnosov/objektov in prisotnost polj merita strukturo, ne pravilnosti, priklica ali vidnih dokazov. Neznano šteje le dobesedni `unknown`, ne vseh izrazov negotovosti. Vsi sprejeti odnosi imajo veljavne sklice in neprazno besedilo dokaza; ta pogoj ne potrdi vsebine fotografije.

Predhodna diagnostika prvega prompta: 1/12 po shemi, 6 ločenih ogrevanj. Zaradi izpuščenih tipov je dodana izrecna JSON tipovna predloga brez vsebinskih primerov; validator in generacijske nastavitve niso razrahljani. Diagnostični odgovori so ohranjeni ločeno in niso prišteti končni primerjavi; ne gre za prikrito popravljanje izhodov.

2. del: vpliv opisov na besedilno presojo

Isti izbor 10+10 slik ostane zamrznjen. Razvrščevalnik Qwen BF16 dobi celoten shranjeni opis, strukturirane objekte in odnose, brez odpiranja fotografije. Uporabljen je isti kratki prompt brez primerov iz 1. dela pri T=.3, seed 42; izbran je zaradi uspešne izpolnitve sheme, ne potrjene vsebinske prednosti. Stare BF16 odločitve se uporabijo ponovno, manjkajoče kontrole starih Q4/Gemma opisov se izvedejo le enkrat.

Opisovalnik	Vhod	OK/vsi	Preskoki	F	M	U	Med. [s]
qwen35-bf16	stari opis	20/20	0	37	63	15	1.6
qwen35-bf16	bogati opis	10/20	7	22	33	9	1.2
qwen35-q4	stari opis	15/20	0	25	48	14	1.0
qwen35-q4	bogati opis	15/20	4	24	63	22	1.4
gemma3-q4	stari opis	18/20	0	26	63	9	1.0
gemma3-q4	bogati opis	16/20	1	33	51	12	1.2

F/M/U so števila odločitev v sprejetih odgovorih. Preskok pomeni zavrnjen vhodni opis; ostane v imenovalcu vseh 20 položajev. Drugačno število objektov med starimi in novimi opisi pomeni, da skupnih ID ne moremo obravnavati kot iste instance.

Opisovalnik	Pari imen	Spremembe razreda
qwen35-bf16	13	3
qwen35-q4	16	5
gemma3-q4	28	6

Pari so le enolična, natančno enaka imena po pretvorbi v male črke in normalizaciji presledkov v obeh veljavnih izhodih iste slike. Podvojena imena se izključijo; sinonimov in okvirjev ne ujemamo. To ni potrjeno ujemanje instanc; skupinska imena so posebej problematična. Sprememba ali strinjanje ni pravilnost. Konkretni pari, ID, SHA256 obeh opisov in oba modelova razloga so v `part2-decision-pairs.csv`.

Ožja kontrola prompta BF16 na istih 20 slikah

Različica opisa BF16	OK/vsi	Med. [s]	Objekti
1. del kratek	20/20	3.4	81
2. del bogati	13/20	12.2	80

Oba prompta sta brez vsebinskih primerov in pri T=0, seed 42. Kratki stari opis se ponovno uporabi iz 1. dela. Nova shema in besedilo se še vedno spreminjata skupaj, zato to ni izolirana ablacija sheme. Za Q4/Gemma primerljivega starega kratkega opisa ni; dodatnih starih klicev za to ne izvajamo.

Obseg, revizija in ponovljivost

Položajev glavne primerjave: 400; odgovorov 388; preskokov 12. Pilot: 12 odgovorov, od tega 12 prekopiranih v glavno primerjavo, brez ponovnega klica. Enkratnih novih merjenih odgovorov brez prve diagnostike: 388. Ločena nova ogrevanja: 16; 6 njihovih kopij se ne šteje ponovno. Revizija 24/24 skupin, kršitev 0; nespremenjenih starih odgovorov 846. Testi: 61 (OK). End-to-end čas novih faz brez predhodne diagnostike: 41.7 min; pilotne kopije in 20 starih presoj niso šteti ponovno. Nalaganje in ogrevanje sta podrobno ločena v agregatih; warmup_reused_from_pilot označi kopijo ogrevanja, new_warmup_calls pa dejanske nove klice. Za prihodnje sveže zagone je kopiranje ogrevanja odpravljeno; izvirne meritve in njihov nalagalni strošek ostanejo nespremenjeni.

```
bash scripts/thud_part2.sh --phase all
python3 -m llm_object_classifier.thud_part2_report --require-complete
python3 -m llm_object_classifier.thud_report
bash scripts/compile_thud_report.sh
```

Surovi izhodi: `results/thud-part2/`; izvorni 1. del ostane v `results/thud-vmesno/`. Dopolnjeni pregled s fotografijami, referenčnimi okvirji, vsemi strukturami in odločitvami: `results/thud-part2/manual-review.html`. Konfiguracije, SHA256 kode, stanje Gita in modeli so v lokalnih manifestih/snapshotih. Ponovni zagon ohrani tudi zavrnitve in preskoke; spremenjeni vhodi se zavrnejo.

2. del: dejanski primeri bogatejšega opisa

thud_dense_test50/frame-000007



Model	Obj./odnosi	Dejanski prvi modelov odnos ali napaka
qwen35-bf16	zavrnjeno	Unknown relation predicate.
qwen35-q4	8/3	refrigerated display unit beside metal shelving unit: separated by an aisle floor
gemma3-q4	5/2	hot air balloon beside shelving unit: The hot air balloon is positioned beside the shelving unit.

Lastna presoja: Q4 in Gemma pravilno postavita glavni hladilni del levo, police desno; Gemma je v starem opisu hladilnike postavila desno. Gemmina nova trditev o lesenih policah ni podprta: vidni nosilci so kovinski. Q4 navaja visible_installation, hkrati installation_evidence=unknown; samega vidnega znaka ne štejemo za dokaz pritrditve celotnega hladilnika. BF16 je zavrnjen zaradi above/below zunaj slovarja, ne zaradi samega prostorskega pomena. Vsi trije še združujejo izdelke. To je delni vizualni pregled.

thud_dense_test50/frame-000030



Model	Obj./odnosi	Dejanski prvi modelov odnos ali napaka
qwen35-bf16	10/4	person beside stacked boxes: standing next to stacked boxes
qwen35-q4	10/2	person beside beverage boxes: Person stands next to stacked beverage boxes.
gemma3-q4	zavrnjeno	Unknown relation predicate.

Lastna presoja: BF16 zdaj loči tri osebe; delno zakrito osebo za moškim označi partial in poveže z behind, stari osnovni opis je ni izpostavil. Q4 in Gemmin zavrnjeni kandidat še navedeta le dve osebi. Referenca People ima le dve regiji, zato tega ne pretvorimo v samodejni priklic. Q4-jev razlog near the refrigerator ne podpira predikata behind. Gemmin kandidat je zavrnjen zaradi above; hkrati opis partially obscured združi z occlusion=none. Trditve BF16 o hoji iz ene fotografije ne morem potrditi. Podpore ostanejo unknown. Delni vizualni pregled, tudi zavrnjenega kandidata.

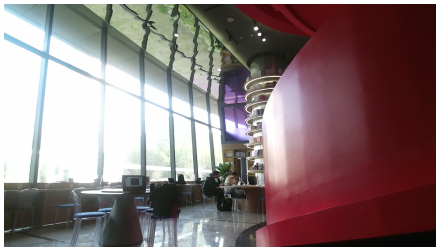
Dejanski besedni razlogi pri parih imen

Opisovalnik / slika / ime	Staro -> bogato	Razlog modela na bogatem opisu
qwen35-bf16 / agtea / image-000045 / large windows	fixed -> uncertain	Windows fixed to building but evidence is not visible.
qwen35-q4 / trgovina / image-000012 / refrigerated display case	uncertain -> movable	Refrigerated display case typically freestanding in retail.
gemma3-q4 / trgovina / image-000028 / person	movable -> uncertain	Person status varies; walking implies temporary presence.

To so modelove utemeljitve, ne potrjena referenca; ujemanje imena ne potrdi iste instance.

2. del: dejanski primeri bogatejšega opisa

thud_agtea_test50/frame-000002



Model	Obj./odnosi	Dejanski prvi modelov odnos ali napaka
qwen35-bf16	5/0	Brez odnosov.
qwen35-q4	5/2	red curved structure beside spiral shelving unit: red structure is adjacent to shelving unit
gemma3-q4	6/3	Table beside Chair: The table and chair are positioned adjacent to each other.

Lastna presoja: BF16 tudi v novem veljavnem izhodu stole opiše kot transparent plastic; vidim kovinske cevne okvirje in modra sedišča. Q4 še združuje tables and chairs. Gemma okno postavi right/top/full, čeprav prevladuje na levi; vijolične svetilke, ki jo navede, ne morem potrditi. BF16 ne vrne nobenega odnosa; Q4 in Gemma vrneta odnose, vendar to še ne potrdi njihove vsebine. Pri vidnih stolih in mizah ostanejo podpore unknown. To je delni vizualni pregled, ne popolna referenca stabilnosti.

thud_agtea_test50/frame-000026



Model	Obj./odnosi	Dejanski prvi modelov odnos ali napaka
qwen35-bf16	zavrnjeno	Unknown relation predicate.
qwen35-q4	8/3	person beside person: seated next to each other at the table
gemma3-q4	6/3	Circular Bookshelf beside Chair: The circular bookshelf is beside the chair.

Lastna presoja: BF16 kandidat je zavrnjen zaradi at in near; zato ne gre v razvrščanje. Dve osebi, krožna polica in modri kovinski stoli v njem so vizualno smiselni, a zakritost vseh označi none. Q4 sprejeti opis loči dve osebi in stola z modrim sedištem; odnos miza under spiral bookshelf zahteva presojo stika in globine, ne le vertikalnega položaja. Gemma si izmisli sive pisarniške stole z nasloni za roke in drugo osebo postavi desno, čeprav sta vidni osebi levo od krožne police. Vsi ohranijo podpore unknown. Namestitve police ne morem potrditi. Delni vizualni pregled, tudi zavrnjenega kandidata.

Sklep in naslednji poskus

Bogatejši zapis omogoča pregled zakritosti in odnosov ter konkreten popravek pri tretji osebi v gostem prizoru. Ne potrjuje pa splošne izboljšave: sprejeti JSON še vsebuje napačne materiale, lokacije in nepodprte dokaze namestitve, številne podpore ostanejo neznane. Večja shema poveča izhod in prinese dodatne zavrnitve. Naslednji kontrolirani poskus naj na istih 20 slikah najprej razjasni slovar odnosov ob nespremenjenih drugih pogojih, nato ločeno preveri tipovno predlogo brez privzetih vrednosti unknown. Neznano mora ostati dovoljeno, kadar dokaz ni viden. Pred končno izbiro modela/prompta je potreben sistematičen ročni pregled istih objektov in stikov. Največ veljavnih JSON ni dokaz najboljše vsebine; brez referenc stabilnosti accuracy ostaja nedoločena.

Nadaljevanje: NVILA-8B in Florence-2-large na RTX 5090

Nova primerjava uporablja istih 100 RGB slik in isti razpršeni podnabor 20 slik. Referenčne vrste in okvirji niso vhod modelov. Prejšnjih uspešnih inferenc Qwen/Gemma ne ponavljamo; v tabelah uporabimo njihove shranjene izhode 2. dela. Rezultati so povezani pogledi dveh prostorov.

Dejanski izolirani zagon in razlike nalog

Oba nova modela sta bila zagnana v ločenih Docker okoljih: Python 3.11, PyTorch 2.7.1+cu128, CUDA 12.8, Transformers 4.46.0. Binarne datoteke vsebujejo sm_120; vsak parameter je preverjeno na GPU. NVILA ima 8,09 milijarde parametrov, Florence približno 0,776 milijarde. Oba dejansko računata v FP16; to ni Qwenova BF16 referenca ali kvantizacija Q4.

NVILA uporablja uradno VILA kodo, pripeto na 57ecbfb904b9, in originalne uteži NVILA-8B. Neposredni izvajalnik odstrani omejitev starega API seznama dovoljenih modelov. Python gostitelja se ne uporablja. Starega torch 2.3/CUDA 12.2 FlashAttention ne namestimo: Qwen2 in SigLIP uporabita SDPA. Učne/FP8 uvoze in neuporabljene vizualne arhitekture izločimo; dinamični S2 ter projektor in uteži ostanejo. Natančen popravek in vse napake so shranjeni. Model ni preimenovan v 15B.

NVILA prejme isti rich-v2 prompt in slikovne bajte kot 2. del, greedy T=0, seed 42, največ 8192 izhodnih tokenov in kontekst 16384. Top-p/top-k sta pri greedy neaktivna. Kazen prisotnosti iz Ollame ni podprta; ločeno uporabimo repetition_penalty=1,05 iz konfiguracije NVILA uteži. Začetni diagnostični pilot z ovojevo vrednostjo 1,0 je dosegel limit in ponavljal zapise; ohranjen je ločeno, brez tihega popravka.

Florence prejme samo tri izvirne kontrolne tokene: `<MORE_DETAILED_CAPTION>`, `<OD>`, `<DENSE_REGION_CAPTION>`. Ne dobi Qwenovega prompta ali sheme. Uporabimo zahtevani osnovni `microsoft/Florence-2-large`, ne različice `-ft`. Nastavitve so največ 1024 tokenov, num_beams=3, do_sample=false, seed 42; pozornost eager. Njegov predprocesor in ločljivost se razlikujeta od dinamičnega S2 in Ollame. Razlike modelov, števila parametrov, dolžin in nalog preprečujejo arhitekturno ali vzročno razlago hitrosti.

Časi vseh odgovorov, tudi zavrnjenih; brez ogrevanja

Model	Naloga	Velj./vsi	Povp. s	Med. s	p90 s
NVILA-8B FP16	rich	0/100	29.18	9.26	133.73
Florence-2-large FP16	caption	100/100	0.42	0.42	0.50
Florence-2-large FP16	od	100/100	0.19	0.14	0.38
Florence-2-large FP16	dense	99/100	0.34	0.23	0.61
Florence-2-large FP16	combined	99/100	0.95	0.83	1.42
Qwen BF16 (staro)	rich-v2	69/100	13.25	11.52	19.00
Qwen Q4 (staro)	rich-v2	82/100	5.13	4.09	6.06
Gemma Q4 (staro)	rich-v2	89/100	4.23	4.15	5.29

Florence combined je neposredno merjen celotni postopek treh zaporednih nalog na sliko, s predprocesiranjem, razčlenjevanjem in zapisi JSON; izris slik je izključen. To ni samo čas ene od nalog. Skupni merjeni čas kombiniranega postopka za 100 slik je 94.97 s. Surovi tokeni in ID-ji so ohranjeni. Števila tokenov različnih tokenizerjev niso neposredno primerljiva. Veljaven zapis ne pomeni pravilnega opisa.

Pomnilnik, lokalizacija in besedilna presoja

Model	Dejanski tipi	Alloc. GiB	Reserv. GiB	Nalag. s
NVILA-8B FP16	torch.float16	16.50	19.55	30.18
Florence-2-large FP16	torch.float16	1.98	2.12	0.69

Allocated/reserved sta procesna vrhova PyTorch, ne isti podatek kot Ollama size_vram. Skupna poraba iz nvidia-smi vključuje namizje in tuje procese; surovi časovni vzorci so shranjeni. Nalaganje je ločeno; tabela kaže zadnjo sejo. Fizično ogrevanje po vsakem nalaganju je izključeno iz glavnih 100 slik: NVILA-8B FP16: 2 klicev, skupaj 9.1 s; Florence-2-large FP16: 9 klicev, skupaj 2.9 s. Začetna diagnostika NVILA je dodatna in ločena. Shranjeni prvi merjeni odgovori se ob nadaljevanju ponovno uporabijo.

Okvirji: dokumentirano ujemanje z anotiranimi regijami

Florence napove xyxy v pikah izvirne slike. Validator preveri končnost, vrstni red in meje; okvirjev ne obrezuje ali popravlja. Izrisanih je do 200 slik (OD in dense za vsako sliko). Ujemanje je po isti sliki/SHA256 in vnaprej določenem slovarju imen (npr. person/people/man/woman → People); brez podnizov ali samodejnega ugibanja samostalnika v dolgi frazi. Pri IoU $\geq 0,5$ uporabimo največje enolično dvodelno ujemanje. Vsak par, imeni in oba okvirja so v extended-box-matches.json; slovar, izključitve in algoritem so v Git.

Nabor	Naloga	Nap. regije	Mapirana imena	Ujem./ref.	Povp. IoU
trgovina	od	147	65	39/495	0.88
trgovina	dense	210	70	10/495	0.81
agtea	od	750	634	303/963	0.82
agtea	dense	793	469	188/963	0.81

To je pokritost anotiranih regij v omejenem slovarju, ne popolna natančnost detekcije. Products/Fruits in druge vrste zunaj slovarja so izključene; skupinska oznaka ne pomeni ene instance. Nepovezana napoved ni avtomatično halucinacija, ker reference niso izčrpne. Dolga dense fraza lahko pravilno opiše regijo, a nima dobesednega razrednega ujemanja. Zato ne poročamo mAP, skupnega precision/recall/F1 ali caption accuracy. Qwen/Gemma in NVILA v tej primerjavi nimajo napovedanih okvirjev; prostorskega besedila ne pretvorimo v IoU.

Drugi korak: isti Qwen BF16 na istih 20 slikah

NVILA veljavni rich opisi ostanejo v celoti nespremenjeni. Pri zavrnjenem rich izhodu ločen transport literal-native-text-v1 ohrani celoten surovi odgovor kot sceno, iz prvega strogo razčlenjenega JSON predponskega objekta pa vzame samo dobesedna imena in celotne izvirne objekte kot opazovanja. Izvirni odgovor ostane zavrnjen, ne postane veljaven rich JSON; nič besedila se ne zavrže. Če ni takega seznama ali so ključi podvojeni, je preskok. To je ločen besedilni preizkus, ne primerjava popolnoma iste vstopne sheme.

Florencejev opis ter OD oznake in dense fraze pretvorimo dobesedno: vsaka izvirna regija dobi lokalni ID in izvirno oznako/frazo ter okvir v besedilu. Regij med nalogama ne združujemo kot isto instanco. Ne dodamo materialov, stikov, namestitev ali odnosov. Transportni not_visible pomeni nepodan/neveljaven dokaz namestitve; identifiable=true označi modelovo imenovano regijo, ne ročne potrditve. NVILA izvirne veljavne oznake dokazov ohranimo; ostale izvirne trditve ostanejo v opazovanju kot modelove trditve. Izhodi in izvorni SHA so zamrznjeni; drugi korak ne bere ali pošilja slik.

Opisovalnik	OK/napaka/preskok	fixed	movable	uncertain
nvila	14/2/4	26	22	13
florence	20/0/0	52	216	98

Razvrščanje uporabi prejšnji short-no-examples prompt, T=0,3, seed 42. Opisi brez veljavnega dobesednega prenosa ostanejo preskočeni; napake razvrščanja niso popravljene. nvila: 16 merjenih klicev, povprečje 2.04 s, največ 8857 vhodnih tokenov; florence: 20 merjenih klicev, povprečje 3.59 s, največ 9913 vhodnih tokenov. Vseh 36 merjenih klicev in štiri izključena ogrevanja imajo potrjen GPU; kontekst je 16384. Različna granularnost regij pomeni, da števila razredov niso accuracy ali strinjanje istih instanc. Referenc stabilnosti ni; razlogi so modelove trditve, ne potrditev dejanskega pritrjevanja.

Dejanski primeri: fotografija in Florence regije

Trgovina / indeks 1



Levo: RGB; sredina: OD; desno: DENSE_REGION_CAPTION. Okvirji so napovedi, ne reference.

Model	Zapis	Dejanski izsek / napaka
NVILA-8B FP16	error	A grocery store aisle with refrigerated shelves on the left and open shelves on the right, filled with various food items such as milk cartons, juice bottles, and packaged goods. The ceiling features colorful h...
Florence-2-large FP16	ok	The image shows the interior of a supermarket aisle with shelves stocked with various products. On the left side of the image, there is a red sign with Chinese characters written on it. The shelves are filled w...
Qwen BF16 (staro)	error	An indoor retail aisle featuring refrigerated display units on the left and open shelving on the right. The ceiling is dark with fluorescent lighting fixtures and hanging hot air balloon decorations. A red sign...
Qwen Q4 (staro)	ok	An indoor retail aisle features a large refrigerated display unit on the left and metal shelving units on the right. The ceiling is dark with fluorescent lighting and decorative hot air balloon decorations hang...
Gemma Q4 (staro)	ok	The photograph depicts a brightly lit supermarket interior. Rows of refrigerated display cases filled with various food and beverage products dominate the scene. Shelves stocked with packaged goods, including c...

Lastni delni vizualni pregled: Florence pravilno opiše hladilni del levo, prodajne police in balonske okraske; okraski so na fotografiji res vidni. OD in dense pa vrneta samo skoraj celotno sliko kot convenience store oziroma supermarket aisle, zato to ni lokalizacija posameznih izdelkov ali polic. NVILA opiše isti prizor, a ne izpolni sheme in doda nepodprto trditev o pritrjenosti polic na steno; navajanje podpore ni dokaz skritih pritrditev. Delni vizualni pregled, brez potrjenih razredov stabilnosti.

Dejanske besedilne presoje novih opisov

Opis	Dobesedni objekt	Razred	Modelov razlog
nvila	Refrigerated shelves	fixed	Attached to wall, not freestanding, requires dismantling to move.
florence	convenience store	uncertain	Label refers to entire store, not specific movable/fixed item
florence	supermarket aisle with hot air balloons	uncertain	Label describes scene and hanging balloons, no clear object attachment

Različna imena niso potrjeno iste instance. To so modelove presoje; brez referenc stabilnosti jih ne štejemo kot accuracy.

Dejanski primeri: fotografija in Florence regije

Trgovina / indeks 6



Levo: RGB; sredina: OD; desno: DENSE_REGION_CAPTION. Okvirji so napovedi, ne reference.

Model	Zapis	Dejanski izsek / napaka
NVILA-8B FP16	error	A grocery store interior with various products and decorations. The ceiling is adorned with colorful hot air balloon-shaped lights, and there are shelves stocked with items like beverages, snacks, and fruits. A...
Florence-2-large FP16	ok	The image shows the interior of a supermarket aisle with a variety of items on display. The aisle is filled with shelves stocked with different types of food and drinks. On the left side of the image, there is ...
Qwen BF16 (staro)	ok	An indoor retail environment with black ceilings and fluorescent lighting. Decorative hot air balloons and red lanterns hang from the ceiling. Shelves on the left hold packaged goods, while a central display fe...
Qwen Q4 (staro)	ok	An indoor retail environment with black ceiling panels and long rectangular fluorescent lights. Decorative hot air balloons in blue/white, yellow, and red/white patterns hang from the ceiling along with red pap...
Gemma Q4 (staro)	error	The photograph depicts a brightly lit supermarket interior. Several shelves stocked with various products are visible, including fruit, beverages, and packaged goods. A customer, wearing a white shirt, is stand...

Lastni delni vizualni pregled: Florence OD okvirji zajamejo velikega moškega levo, osebo zadaj desno in delno zakrito glavo za moškim; to je uporaben uspeh lokalizacije. Kot person in human face označi tudi obraz na plakatu desno, kar ni nova fizična oseba v prostoru. Dense dvakrat vrne skoraj isti okvir delno zakrite glave; podregije/ponovitve ostanejo ločene. NVILA omenja shopping basket pri moškem, ki ga na sliki ne morem potrditi; trditev ostane modelova. Prejšnji Qwen BF16 je v bogatem opisu ločil tri osebe. To ni celotna referenca detekcije.

Dejanske besedilne presoje novih opisov

Opis	Dobesedni objekt	Razred	Modelov razlog
nvila	man in white shirt	movable	Person is not part of the robot map structure.
nvila	shelf with beverages and snacks	movable	Shelf appears freestanding and can be repositioned.
florence	convenience store	movable	Convenience store is a building, not a robot map object.
florence	human face	uncertain	Human face cannot be classified as fixed or movable structure.

Različna imena niso potrjeno iste instance. To so modelove presoje; brez referenc stabilnosti jih ne štejemo kot accuracy.

Dejanski primeri: fotografija in Florence regije

agtea / indeks 1



Levo: RGB; sredina: OD; desno: DENSE_REGION_CAPTION. Okvirji so napovedi, ne reference.

Model	Zapis	Dejanski izsek / napaka
NVILA-8B FP16	error	A modern cafe interior with large windows, a red wall, and a spiral bookshelf. There are tables with laptops and chairs, and people sitting at the tables. The floor is shiny marble, and there's a green plant ha...
Florence-2-large FP16	ok	The image shows the interior of a modern restaurant or cafe. The room has a large window on the left side, allowing natural light to enter the space. The floor is made of marble tiles, and there are several tab...
Qwen BF16 (staro)	ok	An indoor space with large windows on the left letting in bright light. A tall red curved structure dominates the right foreground. In the background, there are tables and chairs where people are seated. A spir...
Qwen Q4 (staro)	ok	An indoor space with large windows on the left letting in bright light. A tall red curved structure dominates the right foreground. In the background, there are tables and chairs where people are seated. A spir...
Gemma Q4 (staro)	ok	The photograph depicts a brightly lit interior space with large windows offering a view of trees and foliage. A curved, red wall dominates the right side of the frame, while a tall window extends across the maj...

Lastni delni vizualni pregled: Florence pravilno postavi veliko okno levo in vrne pregledne okvirje več stolov ter miz. Splošni opis pa dodaja spiral staircase in enjoying their meals; iz te fotografije teh trditev ne morem potrditi. Viden je krožni element s knjigami; opis stopnišča zahteva dodatni dokaz. Okvirji se lahko prekrivajo čez zakrite stole/mize in niso dokaz pravilnih stikov ali materialov. Stari Qwen BF16 je stole napačno opisal kot transparent plastic. Delni vizualni pregled. NVILA pravilno poimenuje spiral bookshelf, vendar doda green plant hanging from ceiling, ki je na tej fotografiji ne morem potrditi. Material marble ostane nepotrjena modelova trditev; odsev tal ga ne dokazuje.

Dejanske besedilne presoje novih opisov

Opis	Dobesedni objekt	Razred	Modelov razlog
nvila	large window	fixed	Large structural window panel integrated into building frame.
nvila	red wall	fixed	Integral part of the building's permanent wall structure.
florence	building	fixed	Building structure requires dismantling to relocate.
florence	chair	movable	Chair can be carried or repositioned in normal use.

Različna imena niso potrjeno iste instance. To so modelove presoje; brez referenc stabilnosti jih ne štejemo kot accuracy.

Dejanski primeri: fotografija in Florence regije

agtea / indeks 6



Levo: RGB; sredina: OD; desno: DENSE_REGION_CAPTION. Okvirji so napovedi, ne reference.

Model	Zapis	Dejanski izsek / napaka
NVILA-8B FP16	error	A modern library interior with a large circular bookshelf and tall windows. The room is well-lit, with natural light coming through the windows and artificial lighting from the bookshelf. There are several peop...
Florence-2-large FP16	ok	The image shows the interior of a modern library with a large window on the left side. The window offers a view of the trees and buildings outside. On the right side of the image, there is a tall spiral stairca...
Qwen BF16 (staro)	error	An indoor space with large windows on the left letting in bright light. A tall, spiral bookshelf structure stands centrally, illuminated by rings of lights. People sit at tables nearby. The floor is reflective.
Qwen Q4 (staro)	ok	An indoor public space with large windows on the left letting in bright daylight. A tall, spiral bookshelf structure stands centrally, illuminated by rings of light. People are seated at tables near the window ...
Gemma Q4 (staro)	ok	The photograph depicts a brightly lit interior space, likely a library or bookstore, with a large window providing natural light. A prominent feature is a tall, circular bookshelf illuminated by internal lights...

Lastni delni vizualni pregled: Florence dense pravilno poimenuje circular bookshelf, vrne regije dveh oseb levo od krožnega knjižnega elementa in več stolov. Splošni caption isti element napačno razlaga kot tall spiral staircase with bookshelves on both sides; več ravni police samo po sebi ni vidno stopnišče. Regionalne fraze wood/black chairs in restaurant niso zanesljiva potrditev materiala, barve ali tipa prostora; vidni so tudi modri sedeži in kovinski okvirji. Razlika med caption in dense je konkreten primer nestrinjanja nalog istega modela. Delni vizualni pregled. NVILA pravilno prepozna circular bookshelf in obodne luči, nato trdi visible mounting hardware/support beams in securely mounted to the floor; teh pritrditev ne morem potrditi. Isti odgovor hkrati pravi, da ni vidno, ali je polica pritrjena na tla ali prostostoječa. To notranje protislovje ostane v surovem besedilu za presojo.

Dejanske besedilne presoje novih opisov

Opis	Dobesedni objekt	Razred	Modelov razlog
nvila	circular bookshelf	uncertain	Evidence of mounting conflicts with description of functional furniture.
florence	building	movable	Building exterior or large structure, typically movable in map context.
florence	person	movable	Person is a biological entity, inherently movable.

Različna imena niso potrjeno iste instance. To so modelove presoje; brez referenc stabilnosti jih ne štejemo kot accuracy.

Sklep nadaljevanja in ponovljivost

Konkretne ohranjene napake in rešitve

Florence se je po 37 shranjenih slikah končal s procesnim izhodom 132 (SIGILL), brez Python izjeme. Nadaljevanje z vključeno sledjo faulthandler je dokončalo vseh 100 slik brez ponovitve že shranjenih odgovorov. Vzrok ni potrjen; ponovnega zagona ne predstavljamo kot dokazanega popravka odvisnosti. En dense izhod agtea, indeks 24, vsebuje obrnjen okvir [0,48; 31,05; 87,84; 0,27]. Celoten izhod ostane zavrnjen; ločen rdeč diagnostični izris ohrani prvotni vrstni red koordinat. Ne obrnemo ga v veljaven okvir in ne vključimo v ujemanje.

NVILA začetno ogrevanje in merjeni pilot z repetition_penalty=1,0 oba dosežeta 8192 tokenov s ponavljanjem JSON. Pri 1,05 je prvi merjeni odgovor kratek, vendar se zanke pri nekaterih drugih slikah še pojavijo. Pogoste so tudi dodatno besedilo za JSON, manjkajoča polja in napačna sintaksa. To so izmerjene omejitve formata modela, ne več nedelujoč GPU. Celotni odgovori, tudi zavrnitve in odmevi navodil, ostanejo shranjeni. Besedilni transport za razvrščanje ne spremeni teh rezultatov validacije.

Po uspešnem zaključku NVILA kontejnerja (izhod 0, vseh 100 odgovorov) je lupinski zaganjalnik javil sintaktično napako. Datoteka je bila med izvajanjem urejena; to je verjetna, ne dokazana razlaga. Razvrščanje je bilo nato uspešno izvedeno ločeno. Novi zaganjalnik najprej razčleni celotno funkcijo. GPU dnevnik ima 374 veljavnih vzorcev in poškodovan zaključek 125 ničelnih bajtov po meritvah; izvirnik ostane shranjen, veljavne vrstice so izvožene ločeno. Vrhovi VRAM v tabelah izhajajo iz inferenčnih zapisov.

Obe zahtevani novi okolji sta pripravljeni za dejansko slikovno inferenco na RTX 5090. Priročnost formata, uspešen GPU zagon in veljavnost izhoda so ločene ugotovitve od vizualne kakovosti. Primerjava vključuje tudi zavrnjene odgovore in razliko med splošnim opisom, detekcijo in regionalnim opisovanjem. Celoten pregled istih 20 fotografij z vsemi starimi/novimi odgovori, referencami in presojami je lokalno v manual-review.html. Preglednica 40 novih model/slika vrstic ostane pending; štirje prikazani primeri so samo delni pregled, ne izmišljena celotna referenca.

Surovi novi izhodi: `results/thud-extended/`; tam so originalni tokeni, razčlenjeni odgovori, konfiguracije, izvorne kode/SHA, pripete uteži, Docker dnevniki, diagnostika in vsi izrisi. Obstoječi odgovori so preverjeni proti indeksu SHA256 pred nadaljevanjem. Git vsebuje kodo, Dockerfile, navodila, agregate, izbrane slike, PDF in LaTeX. Točne revizije modelov in dejanski tipi parametrov so v extended-model-metadata.json in manifestih; dolgi izhodi ostanejo lokalno. Celotna zbirka: 69 testov, 9.065 s, vsi uspešni.

```
bash scripts/thud_extended.sh prepare
bash scripts/thud_extended.sh nvila 1
bash scripts/thud_extended.sh nvila 100
bash scripts/thud_extended.sh florence 1
bash scripts/thud_extended.sh florence 100
bash scripts/thud_extended.sh reason
bash scripts/thud_extended.sh report
python3 -m unittest discover -s tests -v
```

Izvajalnika zahtevata GPU brez CPU nadomestila. Vsako novo nalaganje fizično ogrejeta; že shranjene merjene odgovore (tudi napake) nadaljujeta brez ponovitev. Spremenjeni vhodi/nastavitve zahtevajo ločen poskus. Za vseobsegajoč zagon je na voljo all. Samo faza report ne izvaja inferenc. Neposredni NVILA izvajalnik ne odpira slikovnega API, zato ne trdimo, da stari strežnik deluje.

Naslednji korak naj bo ročni pregled pokritosti posameznih instanc in dejanskih podpor/stikov na istih 20 slikah. Namenske naloge Florence ne zagotovijo ustrezne granularnosti samo s tem, da vrnejo okvirje; NVILA ne postane najboljši model samo zaradi več parametrov ali več besed. Izbira mora upoštevati kakovost in napake skupaj s stroškom. Stabilnosti ne moremo potrditi z eno fotografijo.

Uradni viri: NVILA-8B, pripeta NVIDIA VILA koda, Florence model in izvirne naloge, PyTorch CUDA različice. Preverjeno 21. 10. 2026.